技术能力实测 · 候选人任务书

基于 DSH 的

采购异常处置 Agent

高级全栈工程师（AI Harness 方向）

16 小时（2 天 × 8 小时） · 2026 年 10 月

本次实测在考场预置的 DSH 上进行：插件已装入定制 profile，开考即加载，无需安装。

你只负责这一层——业务工具、会话记忆、技能沉淀，以及能量出来的提效。

请在开考前完整读一遍（约 20 分钟）再动手；开考后不再解释题意，只处理环境故障。

本文档仅供本次应聘者本人使用，请勿外传

本次实测要知道的几件事

项目	采购异常处置 Agent（Procurement Exception Copilot）
平台	重构后的 DSH 定制版：插件已预装，模型、会话、工具运行时、技能目录、权限、界面均由平台提供
模型	DeepSeek V4.1 flash，由 DSH 预设托管；不接 key、不换模型、不写网关
你的角色	写这一层业务能力：工具、记忆、技能、评测；不改 DSH 内核
形式与时长	两天，每天 8 小时，共 16 小时；跨日保留环境与代码
答辩	第二天结束后 60 分钟：陈述 20 分钟 + 追问 30 分钟 + 现场改码 10 分钟
我们提供	六份实例数据、已预装的 pec 插件源码、示例技能、评测样例、备用机器
变更	第二天会宣布一次需求变更，45 分钟内落地
提交	每天收工前提交快照；结束时提交插件包、技能目录与评测报告

这份材料怎么读

第一章讲业务问题，第二章讲数据，第三章讲平台已经给了什么、你还要做什么；第四到七章是四项任务；第八章讲交付。附录是硬口径与样例。

第一章　项目背景	要解决什么问题，做到什么程度，不做什么。	必读
第二章　数据与业务	六份实例数据、租户与权限、业务规则、一次典型处置。	必读
第三章　平台与安排	DSH 提供了什么、模型是什么、两天怎么用、变更与提交。	必读
第四章　任务一	用 defineTool 写 6 个业务工具，配 guard 策略与 render。	主战场
第五章　任务二	让 Agent 记住人：会话记忆与用户记忆。	主战场
第六章　任务三	技能沉淀：从一次对话写出一份可复用的 SKILL.md。	核心
第七章　任务四	提效验证：同一批工单，有技能与没技能。	主战场
第八章　交付	插件包、技能目录、评测报告、答辩。	收工前
附录 A－D	数据字段、业务规则、技能与工具样例、常见问题。	随手查

第一章　项目背景 PART 1 • CONTEXT

1.1　这家公司与你接手的事

星桥智造是一家工程机械配件制造集团，以多租户方式向子公司与经销伙伴提供采购协同能力。主租户 T-001 为集团本部，T-002 为海外事业部，T-003 为经销伙伴租户。本案例为虚构企业，数据与口径参照装备制造业采购履约场景抽象而成。

集团采购部门每天处理大量异常单：交期延迟、库存不足、价格异动、运费异常、供应商风险。中台已经把相关数据整理成六份实例文件，也部署了 DSH 作为智能体平台，但还没有人把这条业务链做成 Agent 能用的工具与技能。

你要做的就是这一层：六个工具、一层记忆、一批技能，外加一套能证明它有用的评测。

1.2　三个具体问题

表 1-1　现状问题与它对你的要求

问题	现状	它对你的要求
查得慢	一张异常单平均跨 4 个数据源、查 7 次，单张 38 分钟	把查询、计算、检索封装成工具，由 Agent 一次调用完成
记不住	同一个采购员第二次问同一件事，助手从头再问一遍	会话记忆与用户记忆分层，避免重复提问
不复用	同类异常每次从头判断，经验留在个人脑子里	把成功处置写成 SKILL.md，下次同类直接命中
说不清	处置意见缺少数据出处，财务退回率 15%	每个数值与条款都要能指回来源
不敢放手	模型直接下结论，出错无人复核	工具只读 + 建议卡 + 规则校验 + 人工确认

1.3　做到什么程度

验收看六个指标，其中提效是最关键的一条：同一个 Agent，在有技能与没有技能两种状态下处理同类工单，差别要能量出来。

表 1-2　本期目标

指标	目标	验证方式
回答准确率	≥ 90%	12 条评测集逐条断言
引用可溯率	100%	回答中的数值与条款都能指回具体记录

指标	目标	验证方式
记忆命中率	≥ 80%	第 2 轮起不重复提问的对话比例
技能复用率	≥ 60%	同类工单命中技能的比例
提效幅度	≥ 30%	同批工单 A/B 的工具调用步数或 token 降幅
越权拦截率	100%	跨租户与字段级越权被拒绝并留痕

1.4 明确不做什么

- **不改 DSH 内核。** | 所有扩展通过插件、工具与技能完成；不要 fork 平台代码。
- **不接模型、不写网关。** | 模型固定为 DeepSeek V4.1 flash，由平台预设托管。
- **不构建业务系统。** | ERP、WMS、合同库都不做，数据已按实例文件提供。
- **不做真实写操作。** | Agent 只产出建议卡与待办，不直接改订单、不下单。
- **不重做聊天界面。** | DSH 的 Web 界面就是交互入口，你通过工具的 render 控制展示。

第二章　数据与业务　PART 2 • DATA

2.1　六份实例数据

数据已导入工作区的 SQLite，开箱即用。你不需要造数据，也不需要写服务。

表 2-1　数据集清单

文件	行数	主要内容
orders.csv	120	订单号、租户、供应商、SKU、数量、单价、下单日、承诺交期、实际交期、状态、物流费单价、体积数
suppliers.csv	32	供应商编码、名称、等级 A–D、黑名单、近 12 月延迟天数、预警联系人
skus.csv	86	SKU、名称、安全库存、当前库存、在途、MOQ、单件体积、阶梯价
contracts.json	46	条款号、供应商、类型、正文、生效日期
tickets.jsonl	28	工单号、订单号、异常类型、处置动作、结论、耗时、是否人工改判
users.json	8	用户 id、姓名、租户、角色、关注品类

28 条历史工单是本次的关键素材：既是「过去怎么处理」的事实来源，也是技能沉淀的输入与提效对比的基线。

2.2　租户与权限

三个租户、六类角色。权限既约束工具，也约束记忆读写。

表 2-2　角色 × 资源（● 全权 / ◐ 脱敏 / ○ 只读 / × 无权）

角色 \ 资源	采购订单	成本价	供应商联系人	合同原文	审计记录
租户管理员	●	●	●	●	○
采购员	●	◐	○	×	○
采购主管	●	●	○	×	○
财务	◐	●	●	●	○
风控	◐	◐	●	◐	○
审计员	○	○	○	○	●

两个易错点

脱敏是返回掩码（如 138****6621），不是返回空值；日志不得留明文。

越权返回 POLICY_DENIED 并留痕，不要返回 404，否则与「数据不存在」无法区分。

2.3 一次典型处置

① **理解：**解析问题，识别订单号、异常类型与诉求；信息不足时追问，不猜测。

② **取证：**调用工具取订单、库存、供应商画像、相似工单；每个结论带来源。

③ **计算与检索：**金额、进位、运费、补货量走纯函数工具；条款走检索，只引用检索到的条款号。

④ **建议：**生成建议卡：动作、参数、依据、风险、置信度、是否需人工确认；规则不过直接否决。

⑤ **复核：**用户确认或修改；修改进入标注集，成为技能沉淀与提效对比的素材。

2.4 业务规则

完整规则见附录 B（R1 – R14）。三条最容易错：

- **进位。**计费体积向上取整到整数立方尺：3.2 → 4，0.4 → 1。
- **舍入。**金额用 DECIMAL 定点 + ROUND_HALF_UP，禁止用 JS number 累加。
- **补货。**补货量 =（安全库存×2 − 当前库存 − 在途），向上取整到 MOQ 整数倍；除数为 0 返回 E_DIV_ZERO。

第三章　平台与安排 PART 3 • PLATFORM

3.1　DSH 已经给了什么

这次不考平台建设，也不考装插件。下面这些能力由考场预置的 DSH 提供，你直接调用；把时间花在业务工具、记忆与技能上。

表 3-1　平台能力与你不需要做的事

能力	DSH 提供	你不用做
插件	pec 插件已预装进定制 profile，开考即出现在工具列表	不装包、不改 profile、不写清单
模型	DeepSeek V4.1 flash，由预设托管；token 用量自动计量	不接 key、不写网关、不做预算
会话	会话持久化、上下文压缩、历史检索	不写存储与压缩
工具运行时	defineTool 注册、参数校验、并发、超时、PTC / native 呈现	不写调度器与校验器
技能目录	扫描 .dsh/skills，解析 frontmatter，文件变化即时生效	不写加载器与检索
权限	沙箱、审批、工具 guard	不写权限中间件
界面	Web GUI、消息流、工具卡渲染	不写前端
批处理	dsh --profile headless 可脚本化执行	不写评测 runner 的进程管理

> **边界**
>
> 允许：写插件、注册工具、写技能、加配置、用平台接口。
>
> 不允许：修改 DSH 内核代码、替换默认模型、绕过沙箱与审批。

3.2　你要做的四件事

- **工具**｜6 个业务工具（defineTool + guard + render），写在预装插件目录里，只读、带 provenance。
- **记忆**｜会话记忆的抽取与注入，用户记忆的存储与隔离。
- **技能**｜至少 2 份 SKILL.md：一份手写，一份由 Agent 从成功对话中沉淀。
- **评测**｜12 条评测集 + A/B 提效对比 + 门禁脚本。

3.3 两天怎么用

表 3-2 时间轴（各 8 小时）

日 / 时段	分钟	内容	里程碑状态
D1 00:00 – 00:30	30	读题、熟悉预装插件结构、写 design.md	示例工具能调用
D1 00:30 – 02:00	90	任务一 A：T1 – T4（订单、供应商、报价、运费）	四个工具可被调用
D1 02:00 – 02:45	45	任务一 B：T5 条款检索、T6 相似工单	检索返回来源
D1 02:45 – 03:15	30	任务一 C：guard 策略与错误语义	越权被拒绝
D1 03:15 – 03:30	15	里程碑 M1	6 工具可调、错误可读
D1 03:30 – 04:30	60	任务二 A：编排与建议卡（工具序列 + 规则校验）	一条工单跑出建议卡
D1 04:30 – 06:00	90	任务二 B：记忆抽取、注入、用户记忆	第二轮不重复提问
D1 06:00 – 07:30	90	任务三 A：手写技能 + 从会话生成技能	两份 SKILL.md 生效
D1 07:30 – 08:00	30	提交 Day1 快照	git tag d1
D2 00:00 – 00:10	10	宣读变更 CR#1	理解影响面
D2 00:10 – 00:55	45	CR#1 落地 + 回归	既有用例不回归
D2 00:55 – 02:00	65	任务三 B：技能匹配、执行与回退	同类工单命中技能
D2 02:00 – 03:20	80	任务四 A：12 条评测集（headless 批跑）	一次跑完出报告
D2 03:20 – 04:20	60	任务四 B：A/B 提效对比	步数或 token 降 ≥30%
D2 04:20 – 05:20	60	失败归因 1 例 + 修复	修复前后对照
D2 05:20 – 07:00	100	打磨：render、建议卡展示、文档、演示	对话里看得清来源
D2 07:00 – 08:00	60	打包、答辩材料	clean 环境可复现

3.4 一次变更

第二天开考时宣布一次需求变更，45 分钟内落地。它会同时碰到工具、技能与记忆三层。

> **关于变更**
>
> 只口头宣布一次，你可以提一个问题；回答是「按你理解的做，并在 CHANGELOG 记录假设」。
>
> 变更之后，既有评测集必须仍然全部通过，并为新行为补至少 2 条用例。
>
> 如果这次变更需要改插件注册以外的代码，说明扩展点没留好。

3.5 提交方式

- **每日快照。** | 每天收工前提交（git tag d1 / d2），工作区干净可重跑。
- **最终交付。** | 插件包 + .dsh/skills + eval/ + 文档，打包为「姓名-PEC-日期.zip」。

- **会话导出。** | 两天的 AI 会话记录，按日分文件夹。
- **演示。** | README 给出三段命令：单轮问答、多轮记忆、技能命中。

3.6 开考前自检

开始前花五分钟确认这几件事，比做到一半发现环境不通划算得多。

- **DSH 能起。** | Web 界面能打开，新建会话能正常回复。
- **预装插件在位。** | pec 插件自带的示例工具出现在工具列表里，能被模型调用一次。
- **数据能查。** | 用 SQLite 客户端能查到 orders 与 suppliers 的行。
- **技能目录能被识别。** | 把示例 SKILL.md 放进 .dsh/skills，目录里能看到它；改一行再刷新，内容跟着变。
- **headless 能跑。** | 执行一次 dsh --profile headless "你好"，能拿到输出。

第四章　任务一：写六个业务工具　TASK 1 • TOOLS

目标：用 defineTool 把数据与业务口径封装成模型可调用、参数可校验、结果可溯源的六个工具。

4.1　六个工具

表 4-1　工具清单

工具	能力	约束
T1 order.lookup	按订单号 / SKU / 供应商查订单、承诺与实际交期、在途、状态	只读；按租户校验；返回来源行 id
T2 supplier.profile	等级、黑名单、近 12 月延迟天数、预警联系人	只读；联系人按角色脱敏
T3 pricing.quote	按 SKU + 数量命中阶梯价，算金额与税额	纯函数；DECIMAL；不得调用模型
T4 freight.calc	体积进位、总运费、计件运费	纯函数；除零返回 E_DIV_ZERO
T5 contract.search	关键词 + 向量召回条款，返回条款号与出处	只读；不得生成未命中条款
T6 ticket.similar	按异常类型 + 供应商 + 金额区间召回历史工单	只读；返回相似度与处置动作

4.2　插件在哪、怎么加工具

pec 插件已经预装并随 profile 加载，源码在 plugins/pec-tools。新增一个工具＝新增一个文件＋在该插件的入口里注册一次，不需要改 profile，也不要碰 DSH 内核。

```
plugins/pec-tools/
├── src/index.ts          # 插件入口：ctx.tools.register(...)
├── src/tools/            # 每个工具一个文件
│   ├── order-lookup.ts
│   └── pricing-quote.ts
├── src/policy/guard.ts   # 租户隔离与脱敏策略
└── package.json          # 已写入 profile，无需改动
```

参数用统一 schema DSL 声明，执行前自动校验；输出声明 schema 与 render，界面按 render 展示。

```
import { defineTool } from '@deepseek-ai/dsh-tools'


ctx.tools.register(defineTool({
  name: 'order.lookup',
  description: '按订单号查询采购订单与履约状态。不适用于按供应商汇总。',
  parameters: {
    orderId: { type: 'string', required: true, description: '采购订单号，如 PO-20261013-0042' },
    tenantId: { type: 'string', required: true, description: '运行时注入，模型不可自填' },
  },
  output: {
    schema: { type: 'object' },
    render: (_args, v) => [{ type: 'text', text: summarize(v) }],
  },
  async execute(args, exec) {
    const row = await db.order.get(args.orderId, args.tenantId, exec.signal)
    if (!row) throw new ToolError('NOT_FOUND', '订单不存在或不属于当前租户')
    return { ...row, provenance: [{ table: 'orders', rowId: row.id }] }
  },
}))
```

- description 写清适用与不适用场景，模型选错工具多半是因为这段没写清楚。
- 参数校验交给平台，你只处理业务错误；错误码统一为 NOT_FOUND / INVALID_ARGUMENT / POLICY_DENIED / UPSTREAM_TIMEOUT。
- 所有结果带 provenance（表名 + 行 id），这是「引用可溯」的数据基础。

4.3 用 guard 做策略

租户隔离与字段脱敏不要写在每个工具里，用平台的工具守卫在调用前统一拦截。

```
ctx.tools.guard((call, next) => {
  const { name, args } = call
  if (name === 'supplier.profile' && args.tenantId !== ctx.session.tenantId) {
    return { deny: 'POLICY_DENIED: 跨租户访问' }
  }
  if (args.tenantId === 'T-002' && !ctx.session.roles.includes('overseas')) {
    return { ask: '该租户数据需要海外事业部权限，是否继续？' }
  }
  return next()
})
```

- 拒绝要留痕：把调用方、工具名、参数摘要写入审计，别只在控制台打一行日志。
- 同一套策略要覆盖技能执行路径——技能里调工具同样过 guard，不能绕过。

4.4 自检

任务一自检清单

① 6 个工具都能被真实调用；② 越权调用返回 POLICY_DENIED 且审计有记录；③ 体积 3.2 得 4、0.4 得 1；④ 数量为 0 时返回 E_DIV_ZERO；⑤ 条款无命中时明确返回「未检索到」；⑥ 每条结果都带 provenance。

第五章　任务二：让 Agent 记住人　TASK 2 • MEMORY

会话本身由 DSH 管理，你要补的是两件事：从对话里抽取值得留下的东西，以及下次把它正确地放回上下文。

5.1　两层记忆

表 5-1　会话记忆与用户记忆

维度	会话记忆	用户记忆
归属	一次会话（一个工单）	一个用户，跨会话
平台已给	会话历史、上下文压缩、按会话检索	无，需要你自建
你要补	抽取白名单字段并写回会话状态	存储、合并、过期、注入
字段数	⩽ 8	⩽ 6
生命周期	会话关闭后 7 天	默认 90 天，可撤销
隔离	会话键含 tenantId	按 tenantId + userId 唯一

5.2　抽取与注入

每轮结束后抽取候选记忆，写入前做去重与冲突判定；下一轮开始时只注入与当前任务相关的 3 – 5 条。

```
{ "userId": "U-07", "tenantId": "T-001", "role": "buyer",
  "focusCategories": ["液压件"],
  "commonSuppliers": ["SUP-1042"],
  "preferAction": { "reschedule": 7, "switchSource": 2 },
  "lastOpenTicket": "EX-2061",
  "updatedAt": "2026-10-13T10:22:00+08:00", "expiresAt": "2027-01-11" }
```

- **白名单。**只抽取白名单字段；金额、数量这类可变事实必须带来源与时间，避免过期值被当成当前值。
- **冲突。**用户显式更正优先于工具推断；冲突时保留较新的一条，并记录被覆盖值。
- **隔离。**跨租户读取一律拒绝；会话键必须含 tenantId。
- **注入。**注入只取相关条目，整包塞回上下文会让 token 失控。

5.3 建议卡

Agent 不直接改订单，只产出建议卡：动作、参数、依据、风险、审批建议、置信度、是否需人工确认。展示交给工具的 render。

```
{ "action": "reschedule", "params": { "orderId": "PO-20261013-0042", "newDate": "2026-10-28" },
  "amount": 57600.00,
  "evidence": [{ "type": "table", "ref": "orders.csv#PO-20261013-0042" },
               { "type": "clause", "ref": "CL-07" }],
  "risks": ["近 12 月延迟 13 天", "金额超过 5 万阈值"],
  "approvalPath": "采购主管", "confidence": 0.82, "needHuman": true }
```

任务二自检清单

① 第二轮不再重复询问已知订单号；② 用户更正后记忆更新并留痕；③ 换租户后旧记忆不生效；

④ 建议卡每个数值都能指回一条记录；⑤ 黑名单供应商的建议被强制标记为需人工确认。

第六章　任务三：技能沉淀与复用　TASK 3 • SKILLS

平台已经提供了技能机制：目录扫描、frontmatter 解析、按需加载、文件变化即时生效。你要做的是「写出好的技能」，以及「让 Agent 自己把成功经验写成技能」。

6.1　一份技能长什么样

技能是放在 .dsh/skills 下的一份 SKILL.md，开头是 YAML frontmatter，正文是给模型读的执行指引。

```
---
name: delay-small-standard
description: 交期延迟且金额低于 5 万的标准处置流程
whenToUse: 异常类型为交期延迟、金额小于 50000、供应商不在黑名单
---


1. 调 order.lookup 取承诺交期与实际交期，算出延迟天数。
2. 调 pricing.quote 用订单数量与单价算出金额，不要自己心算。
3. 调 contract.search 检索「违约金」条款，只引用返回的条款号。
4. 若金额 ≥ 50000 或供应商在黑名单，直接升级人工，不要给自动建议。
5. 输出建议卡：action=reschedule，newDate=实际交期+14 天，附 evidence。
6. 如果 order.lookup 返回 NOT_FOUND，先追问订单号，不要猜。
```

6.2　两份技能

表 6-1　技能交付要求

技能	来源	验收要点
技能 A（手写）	你根据业务规则与历史工单亲手写一份，覆盖最常见的延迟场景	有 whenToUse、有护栏、有反例处理
技能 B（沉淀）	由 Agent 在一次成功对话后自动生成并落盘，下次会话直接命中	能展示生成过程与命中效果

6.3　沉淀怎么写出来

沉淀不是让模型复述一遍对话，而是从这次处置里抽出可复用的结构：触发条件、工具序列、参数来源、护栏、失败处理。

① **触发：**这次属于哪类异常？金额区间、供应商等级、是否黑名单。

② **序列：**调了哪些工具、按什么顺序、哪些参数来自上一工具的输出。

③ **判定：**在哪个点做出决策，依据是哪条规则或哪段条款。

④ **护栏：**什么情况下必须停手、升级或回退。

⑤ **反例：**这次踩过什么坑（例如条款检索无命中），下次怎么避开。

6.4 复用与回退

- **执行。**技能负责给出「最短路径」，模型仍通过工具取数，不得绕过工具直接读表。
- **护栏。**技能里的护栏优先于模型判断；护栏触发即停，转人工或回退通用流程。
- **回退。**任务与技能不匹配时，忽略技能走通用流程，并在 trace 里记录「未命中」。
- **冲突。**同一场景出现两份技能时，按 whenToUse 的约束更严者优先，并在回答中说明选了哪份。

任务三自检清单

① 两份 SKILL.md 都能被平台目录识别；② 技能 B 是在会话结束后自动写出、下一次会话命中；
③ 技能中的护栏真的会拦住越界建议；④ 技能执行路径同样经过 guard；⑤ 未命中时能回退。

第七章　任务四：提效验证　TASK 4 • MEASUREMENT

这一章回答一个问题：技能到底有没有用。答案不能是「感觉快了」，而是一张别人能复核的对照表。

7.1　评测集

自建 12 条，覆盖四类。少于 12 条或只做正向用例，本章视为未完成。

表 7-1　评测集覆盖

类别	条数	典型输入	通过判据
正常	5	典型延迟、缺货、价格异动	结论正确、路径正确、有引用
边界	3	体积 0.4 与 3.2、数量 0、金额恰好 5 万	数值逐位对齐
对抗	2	工具返回夹带指令、跨租户取数	不执行、不越权
记忆 / 技能	2	多轮追问、同类工单技能命中	不重复提问、命中或合理回退

7.2　怎么批跑

用 headless 模式逐条执行，拿 --json 事件流里的工具调用与 token 用量做统计。

```
dsh --profile headless --json "处理 PO-20261013-0042 的交期延迟" > runs/g-02.jsonl

# 统计：工具调用次数、token、耗时、是否命中技能
node eval/collect.mjs runs/ > eval/report.md
```

7.3　提效对比

选 8 条同类工单，用两种状态各跑一遍：

- **A 组（无技能）**｜把 .dsh/skills 临时移走，走通用流程。
- **B 组（有技能）**｜保留技能，命中则按技能执行，未命中回退。
- **对比维度**｜命中率、平均工具调用步数、平均 token、平均耗时、结论一致率。

> **判定标准**
>
> B 组相对 A 组，平均工具调用步数或平均 token 下降 ≥ 30%，且结论一致率不低于 A 组。
>
> 只快不准不算数：结论不一致要逐条说明谁对、为什么。

7.4 指标与门禁

指标	目标
回答准确率	⩾ 90%
引用可溯率	100%
记忆命中率	⩾ 80%
技能复用率	⩾ 60%
提效幅度	⩾ 30%
越权拦截率	100%

- 门禁脚本：任一指标不达标时退出码非 0；报告含 v1/v2 与 A/B 对照。

第八章　交付与验收 DELIVERY

8.1　交付物

交付物	内容	必需性
plugins/pec-tools/	预装插件的源码改动：6 个 defineTool、guard 策略、render	必需
.dsh/skills/	≥ 2 份 SKILL.md（手写 + 沉淀）	必需
memory/	用户记忆存储、抽取规则、注入说明	必需
eval/golden_set.jsonl	≥ 12 条，四类覆盖	必需
eval/run.sh + collect.mjs	headless 批跑与统计脚本	必需
eval/report.md + ab_report.md	指标总表、逐条结果、A/B 对照	必需
traces/	四条：问答、记忆、技能沉淀、技能命中	必需
design.md / README.md / ARCHITECTURE.md	设计、复现步骤、取舍说明	必需
CHANGELOG.md	含 CR#1 的影响面与回归	必需
AI 会话导出	两天记录	必需

8.2　目录结构

```
pec-agent/
├── plugins/pec-tools/         # 预装插件，新增 6 个 defineTool 与 guard
├── .dsh/skills/
│   ├── delay-small-standard/SKILL.md   # 手写
│   └── stock-replenish/SKILL.md        # 会话沉淀
├── memory/  store.json · extract.md
├── eval/    golden_set.jsonl · run.sh · collect.mjs · report.md · ab_report.md
├── traces/  qa · memory · skill-write · skill-hit
└── defense/ slides.pdf 或 defense.md
```

8.3　验收清单

1. **工具合规**｜六个工具都走 defineTool，参数有 schema，结果有 provenance。
2. **策略生效**｜越权被 guard 拦住并留痕，技能路径同样受约束。
3. **算得对**｜金额、进位、计件、补货量逐条对得上附录 B。
4. **记得住**｜第二轮不重复问，用户更正后更新，换租户不串。
5. **写得像**｜SKILL.md 有触发、序列、护栏、反例，不是对话复读。

6. **会自举**｜技能 B 由 Agent 写出并在下次会话命中。
7. **不越界**｜只改 plugins/pec-tools 与 .dsh/skills，预装的其他工具仍可正常调用。
8. **量得出**｜8 条工单 A/B，步数或 token 降幅 ≥ 30%。
9. **讲得明**｜能解释取舍、指出弱点、当场改一处代码。

8.4 答辩

第二天结束后 60 分钟：陈述 20、追问 30、现场改码 10。

- **陈述**｜工具怎么设计、记忆怎么分层、技能怎么沉淀、提效数字怎么来的。
- **追问**｜优先追问提效数字与技能护栏；可能让你打开某个文件指到具体行。
- **改码**｜随机指定一处代码，加一个字段或改一处规则并跑通回归。

附录 APPENDIX

附录 A 数据字段

表 A-1 主要字段

表	字段
orders	id, tenant_id, supplier_id, sku_id, qty, unit_price, promised_at, delivered_at, status, freight_rate, volume
suppliers	id, name, risk_level(A－D), blacklisted, delay_days_12m, contacts(脱敏)
skus	id, name, safety_stock, on_hand, in_transit, moq, volume, price_tiers
contracts	clause_no, supplier_id, type, text, effective_from
tickets	id, order_id, action(reschedule/switch_source/split/replenish), outcome, minutes, overridden
users	id, tenant_id, role, focus_categories

附录 B 业务规则

编号	规则	边界
R1 金额	qty × unit_price，DECIMAL(18,4)，ROUND_HALF_UP 保留 2 位	禁止 JS number
R2 进位	计费体积向上取整；总运费 = 计费体积 × 单价	3.2 → 4；0.4 → 1
R3 计件	ROUND_HALF_UP(总运费 ÷ qty, 2)；qty=0 返回 E_DIV_ZERO	不得返回 0
R4 阶梯价	按总量落唯一区间，跨区间不拆单	99/100、499/500
R5 MOQ	合同优先；低于 MOQ 提示合并或 +5%	不得擅自加价
R6 补货	(安全库存×2 − 当前 − 在途) 向上取整到 MOQ 倍数	860 → 1000
R7 审批建议	<5 万自动；5－20 万主管；≥20 万总监+财务；黑名单一律人工	临界 50,000.00
R8 汇率	进口件按前一日中间价，锁 24 小时，跨日重取	IMP- 前缀
R9 风险	0－100；延迟>10 天 ≥70；黑名单 100 且 D 级	需证据
R10 预警	当前+在途 < 安全库存才触发	等于不触发
R11 权限	跨租户 POLICY_DENIED；成本价仅财务；联系人掩码	拒绝也留痕
R12 引用	数值与条款必须带 provenance，引用不存在条款判幻觉	无出处不下结论
R13 记忆	白名单字段；用户更正优先；会话 7 天、画像 90 天；跨租户不可读	冲突取较新
R14 技能	技能须含护栏；执行同样过 guard；未命中回退通用流程	不得绕过护栏

附录 C　技能样例说明

一份好的技能应当让模型少走弯路：明确先调什么、参数从哪来、什么情况停手。反例是「把整段对话贴进去」，那只是历史记录，不是技能。

- 触发条件写得窄一点，宁可两份技能也不要一份万能技能。
- 每个步骤只写「调哪个工具、传什么参数」，不要写大段业务解释。
- 护栏单独成段，写成「如果……就停止并升级」的句式。
- 末尾加一条反例：本次踩过的坑，下次怎么避开。

附录 D　常见问题

- **需要改 DSH 代码吗？**　不需要。工具通过插件注册，技能通过 SKILL.md 落盘，配置通过 profile。
- **模型能换吗？**　不能。固定为 DeepSeek V4.1 flash，评测与提效数据都在同一模型下比较。
- **技能是代码吗？**　不是。技能是给模型读的指令文件，执行仍通过工具；护栏由技能文本与 guard 共同保证。
- **怎么证明技能生效？**　技能 B 由 Agent 写入后，下一次会话的 trace 里应出现该技能的加载与更短的工具序列。
- **A/B 怎么保证对照干净？**　把 .dsh/skills 临时移走跑 A 组，再放回跑 B 组；同一批工单、同一模型、同一数据。
- **没做完怎么办？**　按已交付部分验收。建议优先保证「一次完整问答 + 一份技能 + 一张 A/B 表」。

如有疑问，请在开考后 15 分钟内提出；开考 15 分钟后只处理环境故障。